

Defensa de los obligatorios — Sistemas Multiagente

Resumen de estudio · Sanes & Guerra · Parcial 08/07/2026. Basado en el informe entregado de Ob2 y el notebook final de Ob1. La pregunta de defensa histórica pide: *qué implementaste, qué funciones de evaluación/algoritmos usaste, qué resultados obtuviste y cómo los explicás.*

Obligatorio 1 — FP, RM, IQL, JAL-AM en juegos repetidos

Qué: 4 algoritmos para N agentes + Random como baseline, validados en MP, RPS, Blotto, BoS, Chicken y Foraging. Torneos round-robin + gráficas de convergencia de políticas.

RPS (suma cero, Nash $\frac{1}{3} \cdot \frac{1}{3} \cdot \frac{1}{3}$)

Resultado: FP y RM convergen al Nash ($[0.33, 0.34, 0.33]$). **IQL y JAL colapsan a Rock con 99%.**

Por qué: Q-learning asume entorno **estacionario**; con dos agentes aprendiendo a la vez esa hipótesis se rompe → colapso casi determinista lejos del equilibrio.

Matching Pennies (suma cero, Nash $\frac{1}{2} \cdot \frac{1}{2}$)

Resultado: FP y RM → $(\frac{1}{2}, \frac{1}{2})$. En el torneo **IQL/JAL le ganan a FP (+0.33)** y FP pierde (-0.33); RM queda ≈ 0 contra ellos.

Por qué: FP **modela al rival**: contra un rival casi determinista intenta explotarlo, se vuelve predecible y termina explotado. RM no modela a nadie → mantiene su mixta estable y no es explotable.

Blotto (21 acciones)

Resultado: FP y RM dominan el torneo ($+0.090$ / $+0.075$); IQL/JAL intermedios; Random pierde (-0.30).

Por qué: FP/RM no convergen a una táctica única sino a una **distribución sobre un subconjunto de tácticas efectivas** — en Blotto no hay estrategia dominante pura.

Battle of the Sexes (coordinación)

Resultado: FP y RM coordinan **casi instantáneo** en un equilibrio puro (Opera). El "2 vs 1" del heatmap FP-RM refleja la **asimetría del equilibrio**, no que un algoritmo sea mejor.

Por qué: a cuál de los 2 EN puros se llega depende de la **inicialización**. IQL/JAL también coordinan pero rinden ~ 0.98 (menos del máximo) por la **exploración residual del ϵ -greedy**.

Chicken (anti-coordinación)

Resultado: IQL/JAL dominan (5.83 / 5.75) y FP/RM quedan últimos (2.84 / 3.45).

Por qué: el colapso determinista de IQL/JAL acá **juega a favor**: convergen a una acción fija, FP responde con la mejor respuesta que le deja el pago chico (2) y ellos se llevan 7. IQL vs JAL caen en (L, L) = 6,6.

Moraleja: **ser predecible se paga distinto según el juego.**

Foraging (único con estados)

Resultado: con 2000 episodios **IQL y JAL alcanzan reward 1.0** (Random 0.72); curvas casi idénticas, estables tras ~1000 episodios.

Por qué: es el único ambiente donde Q-learning tiene sentido: hay **estados y horizonte** — y solo IQL/JAL-AM aplican (tablas Q por estado). Acá se invierte el veredicto de los matriciales.

Conclusión Ob1 (contala así): "FP y RM son los más sólidos en juegos matriciales: convergen al Nash en suma cero y coordinan en BoS; su debilidad es Chicken, donde ser predecible los vuelve explotables. IQL y JAL no sirven para matriciales de un estado (la no-estacionariedad rompe Q-learning y colapsan a políticas deterministas), pero son los únicos que funcionan cuando hay estados: en Foraging llegan al óptimo."

Obligatorio 2 — MCTS, CFR, ISMCTS en juegos alternados

Qué: 3 algoritmos + MiniMax/Random provistos como referencia. Info perfecta: MiniMax/MCTS en Tic-Tac-Toe y Nocca-Nocca. Info imperfecta: CFR/ISMCTS en Kuhn 2P, Kuhn 3P y Leduc. Siempre en **ambas posiciones** promediando; se midió **tiempo por partida**.

Tic-Tac-Toe (control, resoluble)

- MiniMax d1→d3: derrota 0.15→**0.00**, pero tiempo 4ms→170ms (**sin poda α - β y clonando el entorno por nodo, el costo explota**).
- MCTS: con 50 sims ya 0.975 de victoria; **los rollouts extra tienen rendimiento decreciente** — mejor gastar en simulaciones.
- Torneo: ambos aplastan a Random y entre sí **empatan** (juego resuelto). **Abrir da ventaja medible**.

Nocca-Nocca (320 acciones → la eval es central) ★ pregunta tipo 2022

- MiniMax(d1) +0.85 en ~1s; MiniMax(d2) +1.00 pero **21.8s (~22x)**. MCTS +0.50 con mitad de empates por truncamiento.

- **Eval agregada (saber los 3 sumandos):** ① **progreso** hacia la fila objetivo (peso 0.5), ② **control de la pila** (solo las piezas de arriba mueven), ③ **movilidad** (movimientos legales).
- **Ablación:** vs Random → progreso 1.00, completa 0.83, **movilidad sola 0.00**; duelos → completa > progreso > movilidad. **Ranking: movilidad < progreso ≤ completa.**
- Conclusión de diseño: **lo que guía a MiniMax es el progreso**; la movilidad solo complementa.

Kuhn Poker 2P (Nash conocido: $V^* = -1/18 \approx -0.0556$) ★ pregunta tipo 2023

- **CFR converge al Nash:** recompensa final de P0 = $-0.035 \approx -1/18$, con **12 info sets**.
- La estrategia **reproduce la teoría: farol con J** $\approx 1/3$ (0.315 tras pass), **value bet con K** (0.998 tras pass), Q pasiva. "No solo el valor: el equilibrio cualitativo".
- ISMCTS(400) rinde más vs Random (+0.33 vs +0.13) pero es **órdenes de magnitud más caro** (57s vs 0.12s) y sin garantía de Nash.
- **Posición:** P0 (abre) -0.111, P1 +0.0125 → **abrir es desventajoso en Kuhn**, signo consistente con $-1/18$.

Kuhn Poker 3P

- **No existe un Nash único.** CFR N-agente entrena estable: 48 info sets por agente, self-play **suma ≈ 0** .
- **Efecto de posición/orden claro:** ningún asiento es uniformemente mejor; **el último en hablar tiende a beneficiarse**.
- CFR **explota** a 2 Random (+0.372); contra 2 ISMCTS queda parejo (-0.09).

Leduc (6 cartas, 2 rondas, carta comunitaria)

- CFR: ~ 72 info sets, entrenamiento 17→75s (50→200 iter). Vence a Random ya con pocas iteraciones.
- **ISMCTS(100) le gana al CFR entrenado (-0.73)** — saber explicarlo: **no contradice la teoría**; el CFR está **subentrenado** (200 iter, garantía asintótica) mientras ISMCTS hace **búsqueda completa en cada decisión** sin entrenamiento previo.
- **No-monotonicidad** (100 iter → 0.317 pero 200 → 0.185 vs Random): es **varianza de evaluación** (pocas partidas, fichas de rango amplio) — la *explotabilidad* de CFR sí baja monótonamente.

Las 5 conclusiones globales de Ob2:

1. **El eje es el trade-off cómputo↔calidad**, y cada algoritmo lo paga distinto: MiniMax en **profundidad**, MCTS/ISMCTS en **simulaciones por jugada**, CFR en **entrenamiento offline** (una vez, luego juega instantáneo).
2. **Las funciones de evaluación son críticas en juegos grandes** (Nocca-Nocca): progreso domina, movilidad sola no alcanza.
3. **CFR es el método de referencia para info imperfecta** con tiempo de entrenamiento; ISMCTS es la alternativa potente sin entrenamiento, más cara por jugada.
4. **La posición influye en todos los juegos**: abrir es ventaja en tablero y **desventaja en Kuhn**; en 3P el orden reparte ventajas de forma no trivial.
5. **Honestidad sobre la varianza**: se leen tendencias y orden relativo contrastados con la teoría, no decimales.

⚡ Preguntas probables — respuesta en 3 líneas

1. ¿Por qué IQL/JAL no convergen a Nash en RPS/MP pero FP/RM sí?

Q-learning asume entorno estacionario; con ambos aprendiendo, la política del rival cambia y el supuesto se rompe → colapsan a acciones deterministas. FP (modela frecuencias) y RM (regrets) están diseñados para juegos repetidos: FP converge a Nash en suma-cero 2p y el promedio de RM al conjunto de equilibrios correlacionados (= Nash en suma-cero 2p).

2. ¿Por qué ISMCTS le ganó a CFR en Leduc si CFR "converge a Nash"?

Garantía asintótica: 200 iteraciones son pocas para ~72 info sets; ese CFR está lejos de converger. ISMCTS no necesita entrenamiento porque busca (determinizando el estado oculto) en cada jugada — paga el costo por decisión en vez de offline.

3. Describa su función de evaluación y muestre que es buena.

Nocca-Nocca: agregada = progreso (0.5) + control de pila + movilidad; el ranking por ablación (movilidad < progreso ≤ completa) valida los pesos. Ordena finales porque el progreso es máximo exactamente al alcanzar la fila objetivo (ganar); barata (se computa del estado); correlacionada con ganar (validado: d1 ya gana 85%).

4. ¿Qué efecto tuvo la posición?

Tablero: abrir da ventaja medible (TTT y Nocco). Kuhn: abrir es desventajoso ($-1/18$; medimos $P0 -0.111 / P1 +0.013$). Kuhn 3P: sin Nash único, el último en hablar tiende a beneficiarse. Por eso todos los matchups se jugaron en ambas posiciones promediando.

5. ¿FP o RM: cuál es "mejor"?

Convergen a lo mismo en suma-cero, con mecanismos distintos (FP modela al rival y necesita ver sus acciones + su matriz; RM solo sus propios regrets). Diferencia práctica: FP es explotable cuando modelar al rival lo vuelve predecible (Chicken, MP vs IQL); RM se mantiene ≈ 0 contra esos mismos rivales.

6. ¿Por qué el reward de IQL/JAL en BoS es ~ 0.98 y no el máximo?

Exploración residual del ϵ -greedy: ϵ decae pero no llega a 0, así que con cierta probabilidad siguen jugando la acción descoordinada.