

Sistemas Multiagente

Juegos Alternados Funciones de evaluación - Monte Carlo

Sergio Yovine

Universidad ORT Uruguay
yovine@ort.edu.uy

20 de mayo de 2026

Minimax con funciones de evaluación

$$\hat{V}_{\pi_{\text{minimax}}, \pi_{\text{min}}}(s, d) =$$

$$\left\{ \begin{array}{ll} \text{Utilidad}(s) & \text{EsFinal}(s) \\ \text{Eval}(s) & d = 0 \\ \max_{a \in \text{Acciones}(s)} \hat{V}_{\pi_{\text{minimax}}, \pi_{\text{min}}}(Suc(s, a), d - 1) & \text{Jugador}(s) = \text{Agente} \\ \min_{a \in \text{Acciones}(s)} \hat{V}_{\pi_{\text{minimax}}, \pi_{\text{min}}}(Suc(s, a), d - 1) & \text{Jugador}(s) = \text{Oponente} \end{array} \right.$$

$\hat{V}_{\pi_{\text{minimax}}, \pi_{\text{min}}}$ es una *aproximación* de $V_{\pi_{\text{minimax}}, \pi_{\text{min}}}$


Funciones de evaluación: Monte Carlo (Rollout)

- ▶ Repetir r veces
 - ▶ Simular un episodio j desde s
 - ▶ Calcular la utilidad de j : $V_{\pi_a, \pi_o}^j(s)$
 - ▶ Actualizar el valor

$$V_{rollout}(s) = V_{rollout}(s) + V_{\pi_a, \pi_o}^j(s)$$


- ▶ Retornar $V_{rollout}(s)/r$

- ▶ A mayor r , mejor aproximación, pero mayor tiempo de ejecución.
- ▶ Hay que ir hasta un estado final. Puede requerir episodios muy largos.
 - ▶ Acotar la longitud del camino a explorar.
 - ▶ Usar una función de evaluación $Eval_{rollout}(s)$ para estimar la utilidad en el último estado del camino.




Funciones de evaluación: Monte Carlo Tree Search

- ▶ Guardar las estimaciones MC para un subárbol (zona verde)
- ▶ Dentro del árbol, se usa la *política del árbol*
- ▶ Fuera del subárbol, se completa la estimación usando rollout



Funciones de evaluación: Monte Carlo Tree Search



Funciones de evaluación: Monte Carlo Tree Search

▶ Selección

- ▶ descender usando la política del árbol hasta un nodo *expandible*
- ▶ expandible = nodo no final con acciones no exploradas

▶ Expansión

- ▶ elegir una acción no explorada
- ▶ ejecutar la acción
- ▶ agregar al árbol el nodo correspondiente al estado alcanzado

▶ Simulación

- ▶ hacer rollout desde el nodo agregado

▶ Propagación hacia arriba

- ▶ recorrer el camino inverso desde el nodo expandido hasta la raíz
- ▶ actualizar las recompensas acumuladas de los nodos en el camino

Funciones de evaluación: Monte Carlo Tree Search

s : es el estado actual

t : es la cantidad de iteraciones (tiempo)

r : cantidad de rollouts

$\text{mcts}(s, t, r)$:

Crear nodo raíz n_0 con el estado s

for $i = 1, \dots, t$ **do**

 (* Selección *)

$n \leftarrow \text{Select}(n_0)$

 (* Expansión *)

$n \leftarrow \text{Expand}(n)$

 (* Simulación *)

$v \leftarrow \text{Rollout}(n, r)$

 (* Propagar para arriba *)

$\text{Backprop}(n, v)$

 (* Retornar la mejor acción de s *)

return $\text{BestAction}(n_0)$

Funciones de evaluación: Monte Carlo Tree Search

Política del árbol: UCT

► Upper-Confidence Bound for Trees (UCT)

$$UCT(m) = \arg \max_{n \in \text{childs}(m)} UCB(n, m)$$

$$UCB(n, m) = \frac{G(n)}{\text{visits}(n)} + \underbrace{\frac{1}{c}}_{\text{confianza}} \underbrace{\sqrt{\frac{\log \text{visits}(m)}{\text{visits}(n)}}}_{\text{incertidumbre}}$$

$G(\cdot)$: recompensas acumuladas del nodo

Funciones de evaluación: Monte Carlo Tree Search

Selección de la mejor acción

- ▶ Mejor nodo hijo

$$\text{BestChild}(m) = \arg \max_{n \in \text{childs}(m)} \frac{G(n)}{\text{visits}(n)}$$

- ▶ Mejor acción

$$\text{BestAction}(m) = \text{action}(\text{BestChild}(m))$$

Bibliografía

- ▶ R. Sutton, A. Barto. Reinforcement Learning. An Introduction. Cap. 8.10 (Rollout) y 8.11 (MCTS).
- ▶ C. B. Browne et al. A Survey of Monte Carlo Tree Search Methods. IEEE Transactions on Computational Intelligence and AI in Games, vol. 4, no. 1, pp. 1-43, March 2012.