

Sistemas Multiagente


Juegos estocásticos

Sergio Yovine

Universidad ORT Uruguay
yovine@ort.edu.uy


22 de abril de 2026

Juegos estocásticos



S. V. Albrecht et al. Multi-Agent Reinforcement Learning: Foundations and Modern Approaches. (Chapter 3, Fig. 3.1)

Procesos de decisión de Markov con múltiples jugadores



Procesos de decisión de Markov con múltiples jugadores

- ▶ $P = \{1, \dots, n\}$: conjunto de agentes (o jugadores)
- ▶ S : conjunto de estados
- ▶ $EsFinal : S \rightarrow \mathbb{B}$: estados terminales
- ▶ $\mu : S \rightarrow [0, 1]$: distribución de estados iniciales


$$\sum_s \mu(s) = 1 \quad \text{tal que } \mu(s) = 0 \text{ si } EsFinal(s)$$

- ▶ $A = A_1 \times \dots \times A_n$: acciones conjuntas
- ▶ $T : S \times A \times S \rightarrow [0, 1]$: transiciones, tal que para todo $s \in S$ y $a \in A$:

$$\sum_{s'} T(s' \mid s, a) = 1$$

- ▶ $R : S \times A \times S \rightarrow \mathbb{R}^n$: recompensas de cada jugador en cada transición
- ▶ $obs : S \times A \rightarrow O$: observación

Observabilidad parcial



S. V. Albrecht et al. Multi-Agent Reinforcement Learning: Foundations and Modern Approaches. (Chapter 3, Fig. 3.4))

Historias y episodios

- ▶ Una **historia** es una secuencia

$$h^t = s^0 a^0 \dots s^{t-1} a^{t-1} s^t$$

tal que

- ▶ $s^0 \sim \mu$
 - ▶ para todo t , $a_i^t \sim \pi_i(\cdot \mid \text{obs}(h^t))$, con π_i la estrategia de $i \in P$
 - ▶ para todo t , $s^{t+1} \sim T(\cdot \mid s^t, a^t)$
-
- ▶ Una **episodio** es una historia tal que se cumple $EsFinal(s^t)$

Retorno esperado

El **valor** para agente i en la historia h es:

$$V_i^\pi(h) = \sum_{a \in A} \pi(a \mid \sigma(h)) Q_i(h, a)$$

con

$$Q_i^\pi(h, a) = \sum_{s' \in S} T(s' \mid s, a) \left[R_i(s, a, s') + \gamma V_i^\pi(has') \right]$$

s es el último estado de h .

El **retorno esperado** para agente i de la estrategia conjunta π es:

$$U_i(\pi) = \mathbb{E}_{s \sim \mu} V_i^\pi(s)$$

Independent Q-learning (IQL)

Para agente i :

Inicializar: $Q_i(s, a_i) = 0$ para todo $s \in S, a_i \in A_i$

Repetir:

$s \sim \mu$

Repetir hasta que s sea terminal:

Con prob. ε elegir $a_i \sim \mathcal{U}(A_i)$, si no $a_i = \arg \max Q_i(s, \cdot)$

Observar r_i y s'

$Q_i(s, a_i) \leftarrow Q_i(s, a_i) + \alpha [r_i + \gamma \max Q_i(s', \cdot) - Q_i(s, a_i)]$

$s \leftarrow s'$

- ▶ Ventaja: simple y escalable (e.g., deep reinforcement learning)
- ▶ Desventaja: puede no converger a un equilibrio de Nash

Joint-action learning usando teoría de juegos (JAL-GT)

Para agente i :

Inicializar: $Q_j(s, a) = 0$ para todo $j \in P, s \in S, a \in A$

Repetir:

$$s \sim \mu$$

Repetir hasta que s sea terminal:

Con prob. ε elegir $a_i \sim \mathcal{U}(A_i)$, si no $a_i \sim \pi_i^s$ t.q. $\pi^s = \text{Solve}(\Gamma^s)$

Observar $a = (a_i, a_{-i})$, (r_i, r_{-i}) y s'

Para todo j : $Q_j(s, a) \leftarrow Q_j(s, a) + \alpha [r_j + \gamma \text{Value}_j(\Gamma^{s'}) - Q_j(s, a)]$

$$s \leftarrow s'$$

tal que:

- ▶ Γ^s es el juego (en forma normal) dado por $Q(s, \cdot)$
- ▶ $\text{Solve}(\Gamma^s)$ devuelve un equilibrio π^s de Γ^s
- ▶ $\text{Value}_j(\Gamma^s) = \sum_{a \in A} \Gamma_j^s(a) \pi^s(a)$ es el valor del equilibrio

Ejemplo: Minimax Q-Learning (Littman 1994) para juegos de suma cero dos jugadores.

JAL-GT: inconvenientes

- ▶ En general, no se puede aprender las estrategias de equilibrio en todos los casos solo con $Q_i(s, a)$
- ▶ *Prescribe* cómo se deben comportar los agentes en equilibrio, por ejemplo, resolviendo los juegos con minimax.

Joint-action learning usando agent modeling (JAL-AM)

Para agente i :

Inicializar:

$Q_i(s, a) = 0$ para todo $s \in S, a \in A$

$\pi_j(\cdot | s) = \mathcal{U}(A_j)$ para todo $j \neq i, s \in S$

Repetir:

$s \sim \mu$

Repetir hasta que s sea terminal:

Con prob. ε elegir $a_i \sim \mathcal{U}(A_i)$, si no $a_i = \arg \max AV_i(s, \cdot)$

Observar $a = (a_i, a_{-i})$, r_i y s'

Para todo $j \neq i$: actualizar π_{-j}

$Q_i(s, a) \leftarrow Q_i(s, a) + \alpha [r_i + \gamma \max AV_i(s', \cdot) - Q_i(s, a)]$

$s \leftarrow s'$

con:

$$AV_i(s, a_i) = \sum_{a_{-i}} Q(s, (a_i, a_{-i})) \pi_{-i}(a_{-i} | s)$$

Bibliografía recomendada

- ▶ S. V. Albrecht, F. Christianos and L. Schäfer. Multi-Agent Reinforcement Learning: Foundations and Modern Approaches. MIT Press, 2024. Chapter 4. Sec. 4.1. Chapter 5. Sec. 5.3. Chapter 6. Secs. 6.2, 6.2.1 y 6.3.2
- ▶ M. L. Littman. Markov games as a framework for multi-agent reinforcement learning. ICML. Vol. 94. 1994.

Bibliografía

- ▶ Multi-Agent Reinforcement Learning: Independent vs Cooperative Agents. Ming Tan. ICML. 1993.
- ▶ Uther, William and Manuela Veloso (1997). Adversarial reinforcement learning. Technical Report CMU-CS-03-107. Carnegie Mellon University.